

## Avaliação 4 - Análise Fatorial - Parte 2

```
dados <- data.frame(
  Ca = c(2.3, 2.5, 1.8, 3.4, 1.8, 3.7, 1.4, 1.5, 2.8, 1.4, 1.8, 1.9, 2.8),
  Mg = c(1.7, 2.5, 2.1, 2.5, 1.1, 1.4, 0.7, 0.6, 2.2, 0.8, 0.6, 1.7, 0.8),
  SB = c(4.1, 5.1, 4.1, 6.1, 3.0, 5.2, 2.2, 2.2, 5.1, 2.3, 2.5, 3.7, 3.7),
  ts = c(7.5, 7.4, 6.4, 8.4, 6.5, 8.5, 4.7, 4.0, 9.0, 3.7, 7.2, 6.0, 5.9)
)

dados
```

```
##      Ca  Mg  SB  ts
## 1  2.3 1.7 4.1 7.5
## 2  2.5 2.5 5.1 7.4
## 3  1.8 2.1 4.1 6.4
## 4  3.4 2.5 6.1 8.4
## 5  1.8 1.1 3.0 6.5
## 6  3.7 1.4 5.2 8.5
## 7  1.4 0.7 2.2 4.7
## 8  1.5 0.6 2.2 4.0
## 9  2.8 2.2 5.1 9.0
## 10 1.4 0.8 2.3 3.7
## 11 1.8 0.6 2.5 7.2
## 12 1.9 1.7 3.7 6.0
## 13 2.8 0.8 3.7 5.9
```

### a. Matriz de correlações


```
matriz_correlacoes <- cor(dados)
matriz_correlacoes
```

```
##           Ca           Mg           SB           ts
## Ca 1.0000000 0.5264162 0.8743404 0.7933416
## Mg 0.5264162 1.0000000 0.8723765 0.6743725
## SB 0.8743404 0.8723765 1.0000000 0.8373290
## ts 0.7933416 0.6743725 0.8373290 1.0000000
```

```
library(corrplot)
```

```
## corrplot 0.92 loaded
```

```
corrplot(matriz_correlacoes, method = "number", type = "upper")
```



A correlação entre Ca e SB é alta, sugerindo que essas variáveis estão relacionadas fortemente. Já a correlação entre Ca e Mg é moderada, sugerindo que essas variáveis estão relacionadas, mas de forma menos intensa.

## b. Viabilidade da Análise Fatorial

```
library(psych)

bartlett_test <- cortest.bartlett(dados)
```

```
## R was not square, finding R from data
```

```
bartlett_test

## $chisq
## [1] 89.29183
##
## $p.value
## [1] 4.251157e-17
##
## $df
## [1] 6
```

```

kmo_test <- KMO(dados)
kmo_test

## Kaiser-Meyer-Olkin factor adequacy
## Call: KMO(r = dados)
## Overall MSA = 0.53
## MSA for each item =
##   Ca   Mg   SB   ts
## 0.45 0.42 0.52 0.92

library(gridExtra)

resultados <- data.frame(
  Teste = c("Bartlett", "KMO"),
  Valor = c(bartlett_test$chisq, kmo_test$MSA),
  p_valor = c(bartlett_test$p.value, NA),
  stringsAsFactors = FALSE
)

grid.table(resultados)

```

	Teste	Valor	p_valor
1	Bartlett	89.29183	4.251157e-17
2	KMO	0.53253	NA

```

#kable(resultados, col.names = c("Teste", "Valor", "p-valor"), align = "c")

```

O teste retornou um valor de 89,29183, assim pode-se rejeitar a hipótese nula, ou aceita-se que a hipótese de que há variância significativa, que é, por sua vez, adequado à Análise Fatorial.

Se obteve KMO de 0,53253 ( $< 0,6$ ), indicando que a Análise Fatorial pode não ser apropriada para os dados fornecidos.

### c. Ajuste do Modelo Fatorial

```
# Ajuste
```

```
fa_model <- fa(dados, nfactors = 2, rotate = "varimax", fm = "pa")
```

```
# Cargas fatoriais
```

```
loadings <- as.data.frame(fa_model$loadings[])  
colnames(loadings) <- c("Fator1", "Fator2")
```

```
# Comunalidades
```

```
comunalidades <- as.data.frame(fa_model$communality)  
colnames(comunalidades) <- "Comunalidade"
```

```
library(grid)
```

```
grid.table(loadings)
```

	Fator1	Fator2
Ca	0.96745078199961	0.250771025913005
Mg	0.297365156070358	0.954488619651489
SB	0.724456375894739	0.687646601095655
ts	0.692840391811692	0.490185323285822

```
grid.newpage()
grid.table(comunalidades)
```

	Comunalidade
<i>Ca</i>	0.998847123029118
<i>Mg</i>	0.999474561088953
<i>SB</i>	0.997694888572947
<i>ts</i>	0.720309459690606

Sugere-se que há uma forte associação entre as variáveis e o Fator 1. As comunalidades sugerem que os fatores explicam bem a maior parte da variância.

#### d. Proporção da variabilidade total por cada fator

```
variabilidade_explicada <- as.data.frame(fa_model$Vaccounted)
colnames(variabilidade_explicada) <- c("Fator1", "Fator2")
```

```
grid.newpage()
grid.table(variabilidade_explicada)
```

	Fator1	Fator2
<i>SS loadings</i>	2.02925190073672	1.6870741316449
<i>Proportion Var</i>	0.507312975184181	0.421768532911225
<i>Cumulative Var</i>	0.507312975184181	0.929081508095406
<i>Proportion Explained</i>	0.546037103056932	0.453962896943068
<i>Cumulative Proportion</i>	0.546037103056932	1

A variabilidade total pode ser demonstrada pelo Fator 1. Quanto ao Fator 2, as variáveis podem não ser bem explicadas por ele.

#### e. Escores fatoriais do Fator 1

```
escores_fatoriais <- as.data.frame(factor.scores(dados, fa_model)$scores)
colnames(escores_fatoriais) <- c("Fator1", "Fator2")
```

```
grid.newpage()
grid.table(escores_fatoriais[1])
```

	Fator1
1	0.000921042913633084
2	-0.00281553426537189
3	-0.972935101052268
4	1.25189816230169
5	-0.512911534220209
6	2.1970823120494
7	-0.94931544368374
8	-0.758954145520357
9	0.550107238251202
10	-0.982214856215361
11	-0.327308302782007
12	-0.588186685456478
13	1.09463284767986