

SÉRIES TEMPORAIS



AVALIAÇÃO: LISTA DE EXERCÍCIOS (LE2)

I) Informações gerais

Conteúdo: Modelos ETS e VAR

Tempo (estimado): 8 horas/aula

Professora: Sheila Regina Oro

Discente(s): **Cintia Izumi Shinoda**

Referências:

1. BARROS, A.C.; MATTOS, D.M. OLIVEIRA, I.C.L.; FERREIRA, P.G.C.; DUCA, V.E.L.A. **Análise de Séries Temporais em R: Curso Introductório**. Rio de Janeiro: Elsevier: FGV IBRE, 2017. pág.84 – 151. Disponível em: <https://webapp.utfpr.edu.br/bibservices/minhaBiblioteca?ISBN=9788595154902/>
2. MORETIN, P. A.; TOLOI, C.M.C. **Análise de séries temporais** – Vol I, 3ed. São Paulo: Editora Blucher, 2018. pág.70 – 83 e 108 – 182 . Disponível em: <https://webapp.utfpr.edu.br/bibservices/minhaBiblioteca?ISBN=9788521215349/>
3. SOUSA, A. R. S.; SILVA, C.; SILVA, J. S. F.; et al. **Análise de séries temporais**. Porto Alegre: SAGAH, 2021. pág.16 – 19, 55 – 69 e 87 – 122. Disponível em: <https://webapp.utfpr.edu.br/bibservices/minhaBiblioteca?ISBN=9786556902876/>
4. Hyndman, R.J.; Athanasopoulos, G. **Forecasting: principles and practice**, 2ed, Melbourne: Otexts, 2018. Disponível em: <https://otexts.com/fpp2> .

Avaliação:

A avaliação será realizada para cada exercício.

As respostas devem ser registradas exclusivamente neste documento e na sequência dos enunciados dos exercícios.

II) LISTA DE EXERCÍCIOS

Com base nos conteúdos abordados nas aulas e nas referências indicadas, responda o que se pede.

1. Utilize a mesma planilha de dados da primeira Lista de exercícios (L1).

- a. Separe os dados em um conjunto de treinamento, contendo os 88 primeiros valores da série temporal.

```
library(readxl)
```


```
dados <- read_excel("exercicio1.xlsx")
dados.serie <- ts(dados, start = c(1989,5), frequency=12)
dados.treino <- ts(dados.serie[1:88], start = c(1989,5), frequency=12)
dados.treino
```

```
##      Jan  Feb  Mar  Apr  May  Jun  Jul  Aug  Sep  Oct  Nov  Dec
## 1989                49.61 49.54 49.81 49.94 50.33 50.21 49.88 49.59
## 1990 50.04 50.75 50.66 50.23 49.73 49.44 49.62 49.74 50.10 50.05 50.15 49.99
## 1991 50.15 50.59 50.43 50.03 50.13 50.36 49.79 49.90 50.24 50.22 49.73 49.25
## 1992 49.63 49.90 50.15 50.56 50.42 49.82 49.84 50.09 49.98 50.24 50.45 50.22
## 1993 49.97 50.27 50.61 49.88 49.84 50.26 49.82 49.86 49.75 50.27 50.59 49.83
## 1994 49.64 49.93 49.67 50.03 50.35 49.56 49.52 49.91 49.72 49.93 49.98 50.08
## 1995 50.30 50.27 49.76 49.74 49.67 49.67 49.87 49.96 49.65 49.48 49.79 49.33
## 1996 49.81 50.48 50.13 50.03 49.99 50.27 50.35 49.90
```

- b. Usando o conjunto de treinamento, estime os modelos Holt-Winters, ARIMA e ETS.


```
# Modelo Holt-Winters
HW <- hw(dados.treino, h=12)
cpgram(HW$residuals, main="Periodograma Integrado - Resíduos Holt-Winters")
```

Periodograma Integrado - Resíduos Holt-Winters




```
# Modelo ARIMA  
ARIMA <- auto.arima(dados.treino)  
cpgram(ARIMA$residuals, main="Periodograma Integrado - Resíduos ARIMA")
```

Periodograma Integrado - Resíduos ARIMA



```
# Modelo ETS  
ETS <- ets(dados.treino)  
cpgram(ETS$residuals, main="Periodograma Integrado - Resíduos ETS")
```

Periodograma Integrado - Resíduos ETS



- c. Apresente as estimativas (usando o comando `summary`) e interprete os principais resultados.

```
summary(HW)
```

```
##
## Forecast method: Holt-Winters' additive method
##
## Model Information:
## Holt-Winters' additive method
##
## Call:
## hw(y = dados.treino, h = 12)
##
## Smoothing parameters:
##   alpha = 0.201
##   beta  = 1e-04
##   gamma = 1e-04
##
## Initial states:
##   l = 49.9625
##   b = 8e-04
##   s = 0.0691 0.2173 0.3246 -0.0554 -0.2147 0.0859
##       0.0571 -0.0137 -0.0835 -0.1757 -0.1352 -0.076
##
##   sigma: 0.3145
##
##      AIC      AICc      BIC
## 206.7487 215.4916 248.8634
##
## Error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.003434773 0.284466 0.2401205 0.003951039 0.4801625 0.7056907
##              ACF1
## Training set 0.3715747
##
## Forecasts:
##      Point Forecast    Lo 80    Hi 80    Lo 95    Hi 95
## Sep 1996    50.07634 49.67330 50.47937 49.45995 50.69272
## Oct 1996    50.14794 49.73684 50.55904 49.51921 50.77666
## Nov 1996    50.17753 49.75851 50.59655 49.53669 50.81837
## Dec 1996    49.87763 49.45082 50.30443 49.22489 50.53036
## Jan 1997    50.03779 49.60334 50.47224 49.37335 50.70222
## Feb 1997    50.41855 49.97658 50.86053 49.74261 51.09449
## Mar 1997    50.31201 49.86263 50.76140 49.62475 50.99928
## Apr 1997    50.16460 49.70793 50.62128 49.46618 50.86302
## May 1997    50.02030 49.55645 50.48416 49.31089 50.72971
## Jun 1997    49.96189 49.49095 50.43283 49.24165 50.68213
## Jul 1997    49.92218 49.44426 50.40011 49.19126 50.65310
## Aug 1997    50.01517 49.53035 50.49998 49.27371 50.75663
```

As previsões ficaram em torno de 50, com intervalos de confiança 80% e 95% e apresentou um MAPE de 4.08%, que parece aceitável.

```
summary(ARIMA)
```

```
## Series: dados.treino
## ARIMA(0,0,1) with non-zero mean
##
## Coefficients:
##      ma1      mean
##      0.8326  49.9900
## s.e.  0.0609  0.0482
##
## sigma^2 = 0.06304: log likelihood = -2.83
## AIC=11.66  AICc=11.95  BIC=19.09
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.0002144196 0.248206 0.205933 -0.001972059 0.4120692 0.605217
##              ACF1
## Training set -0.0371395
```

O MAPE se apresenta extremamente baixo (0.41%), indicando um ótimo ajuste.

```
summary(ETS)
```


```
## ETS(A,N,N)
##
## Call:
## ets(y = dados.treino)
##
## Smoothing parameters:
##   alpha = 1e-04
##
## Initial states:
##   l = 49.9915
##
## sigma: 0.321
##
##      AIC      AICc      BIC
## 197.9701 198.2558 205.4021
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.000100458 0.3172931 0.259634 -0.004224772 0.5191131 0.7630389
##              ACF1
## Training set 0.4447305
```

A medida de MAPE é 0,52%, indicando que o modelo apresenta ótima precisão.

- d. Plote os modelos obtidos para a série temporal, com as previsões para os últimos 12 meses. Comente sobre as características perceptíveis no gráfico.

```
# Modelo Holt-Winters  
plot(HW)  
lines(dados.serie)
```

Forecasts from Holt-Winters' additive method




O modelo foi capaz de identificar e modelar com sucesso os componentes sazonal e de tendência da série temporal.

As previsões sugerem que a série continuará a apresentar o mesmo padrão sazonal nos próximos períodos, com um leve crescimento na tendência.

```
# Modelo ARIMA  
plot(forecast(ARIMA,h=12))  
lines(dados.serie)
```


Forecasts from ARIMA(0,0,1) with non-zero mean



As previsões se mostram estáveis, flutuando em torno de um valor central.

```
# Modelo ETS  
plot(forecast(ETS,h=12))  
lines(dados.serie)
```

Forecasts from ETS(A,N,N)



As previsões se mostram bastante estáveis.

- e. Apresente a acurácia dos modelos nas fases de treinamento e de previsões e interprete os resultados.

```
# Modelo Holt-Winters
accuracy(HW, dados.serie[89:100])
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.003434773 0.2844660 0.2401205 0.003951039 0.4801625 0.8715263
## Test set    0.036506005 0.2738078 0.2510017 0.071215313 0.5002521 0.9110198
##              ACF1
## Training set 0.3715747
## Test set     NA
```

O modelo Holt-Winters obteve bons resultados no treinamento. Os valores relativamente baixos de RMSE, MAE e MAPE sugerem que o modelo está capturando bem os padrões da série.

Na fase de previsão, houve piora no desempenho (quando comparado à fase de treinamento), porém é o esperado.

```
# Modelo ARIMA
accuracy(forecast(ARIMA, h=12), dados.serie[89:100])
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.0002144196 0.2482060 0.2059330 -0.001972059 0.4120692 0.7474415
## Test set    0.1521779025 0.2242274 0.1871709 0.302452008 0.3726077 0.6793437
##              ACF1
## Training set -0.0371395
## Test set     NA
```

Na fase de treinamento, o modelo ARIMA também obteve bons resultados e na fase de previsão também houve piora do desempenho.

```
# Modelo ETS
accuracy(forecast(ETS, h=12), dados.serie[89:100])
```

```
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set -0.000100458 0.3172931 0.2596340 -0.004224772 0.5191131 0.9423513
## Test set    0.139337553 0.2228735 0.1850854 0.276747439 0.3684440 0.6717744
##              ACF1
## Training set 0.4447305
## Test set     NA
```

O modelo ETS apresentou também bons resultados na frase de treinamento com valores de RMSE, MAE e MAPE relativamente baixos e valor o valor ME próximo de zero indica que o modelo não possui um viés significativo.

Na fase de previsão, houve uma piora (esperada) no desempenho.

- f. Com base nos resultados obtidos nos itens anteriores, indique qual dos modelos ajustados foi melhor.

O modelo ARIMA foi o melhor.

O modelo ARIMA apresentou bons resultados no ajuste dos dados de treinamento e capacidade de generalização para novos dados. Já, os modelos ETS e Holt-Winters obtiveram resultados semelhantes: razoáveis no conjunto de treinamento, porém com capacidade de generalização limitada.



Exceto quando mencionado explicitamente, ou quando se tratar de citação direta ou indireta, ou quando se tratar de material alheio incorporado (como vídeos do youtube), nos limites estabelecidos pela Lei 9.610/98, todo conteúdo deste material está licenciado sob uma Licença [Creative Commons CC-BY-SA - Atribuição-Compartilha Igual 4.0 Internacional](https://creativecommons.org/licenses/by-sa/4.0/).